

# Using neural networks for popularity prediction of online video content

Raport z postępów w pracy inżynierskiej

*Bocheński Tomasz*

3 lipca 2016

## 1 Podsumowanie obecnego semestru

W obecnym semestrze poczyniłem następujące postępy.

### 1.1 Wybór źródeł danych do nauki i testowania sieci

Spośród dostępnych serwisów internetowych z filmikami wybrałem cztery, które moim zdaniem najlepiej nadają się jako źródła danych. Są nimi: Facebook, Youtube, Dailymotion, Vimeo. Wszystkie one cechują się dużą popularnością, dużą bazą filmików oraz udostępniają API pozwalające na uzyskanie satysfakcjonujących metadanych. Następnie dla każdego z tych serwisów, wspólnie z kolegą, stworzyliśmy listy najbardziej aktywnych użytkowników i kanałów. Poniżej przedstawiam podsumowanie ich ilości:

- Youtube: 1120
- Facebook: 144
- Dailymotion: 865
- Vimeo: 49

Listy te można znaleźć tutaj: <https://github.com/tom3097/VideoPopularityPrediction/tree/master/VideoCrawlers/data>

### 1.2 Stworzenie web crawlerów (robotów internetowych)

Następnie zapoznałem się dokładniej z API przedstawionych powyżej serwisów internetowych oraz napisałem odpowiednie roboty internetowe dla każdego z nich. Poniżej przedstawiam podsumowanie ilości filmików dla których metadane zostały pobrane wraz z ich całkowitą wielkością (bez uwzględnienia filtrowania):

- Youtube: liczba filmików - 419046, całkowity rozmiar - 1.8 GB
- Facebook: liczba filmików - 195945, całkowity rozmiar - 922 MB
- Dailymotion: liczba filmików - 1811543, całkowity rozmiar - 3GB
- Vimeo: liczba filmików - 98078, całkowity rozmiar - 897 MB

Oraz przykładowe metadane uzyskane dla jednego pliku video dla każdego z serwisów internetowych:

- Youtube:

```
{
  "channel_UC": "UCzzYnZ8GIzfB1Vr3hk2Nj9Q",
  "date_time": "2016-05-21 09:17:32",
  "etag": "\"\zekp1FB4kTkkM-rWc1qIAAt-BWc/PlH3kUy4HPS_G2mFNvMXGuQMgmQ\"",
  "id": "cNeU6QbejDs",
  "kind": "youtube#video",
  "snippet": {
    "categoryId": "22",
    "channelId": "UCzzYnZ8GIzfB1Vr3hk2Nj9Q",
    "channelTitle": "Tiger Fitness",
    "description": "SUPPORT MARC LOBLINER'S COMPANY AND SHOP
AT TIGERFITNESS.COM! http://www.tigerfitness.com\n\nMarc and
The Hollywood Militia NOW OFFER COACHING Email mlobliner@gmail.com
or john.hollywood.tcoach@gmail.com\n\nTHE INTRO AND OUTRO SONG!"
    "liveBroadcastContent": "none",
    "localized": {
      "description": "SUPPORT MARC LOBLINER'S COMPANY AND SHOP AT
TIGERFITNESS.COM!",
      "title": "Creatine While Cutting"
    },
    "publishedAt": "2013-07-23T20:40:57.000Z",
    "tags": [
      "muscle and fitness",
      "work out routines",
      "tigerfitness.com",
      "ethitech nutrition",
      "marc lobliner",
      "Lobliner",
      "machine",
      "mts nutrition"
    ],
    "thumbnails": {
      "default": {
        "height": 90,
        "url": "https://i.ytimg.com/vi/cNeU6QbejDs/default.jpg",
        "width": 120
      },
      "high": {
        "height": 360,
        "url": "https://i.ytimg.com/vi/cNeU6QbejDs/hqdefault.jpg",
        "width": 480
      },
      "maxres": {
        "height": 720,
        "url": "https://i.ytimg.com/vi/cNeU6QbejDs/maxresdefault.jpg",
        "width": 1280
      },
      "medium": {
```

```

        "height": 180,
        "url": "https://i.ytimg.com/vi/cNeU6QbejDs/mqdefault.jpg",
        "width": 320
    },
    "standard": {
        "height": 480,
        "url": "https://i.ytimg.com/vi/cNeU6QbejDs/sddefault.jpg",
        "width": 640
    }
},
"title": "Creatine While Cutting"
},
"statistics": {
    "commentCount": "192",
    "dislikeCount": "20",
    "favoriteCount": "0",
    "likeCount": "1247",
    "viewCount": "79760"
}
}
}

```

- Facebook:

```

{
    "content_category": "NEWS",
    "created_time": {
        "date": "2016-02-25 12:00:00.000000",
        "timezone_type": 1,
        "timezone": "+00:00"
    },
    "description": "What do you want to know about the Syrian war and the refugee crisis? On The Line will take your questions today at 12pm ET.\n\nWe want to hear from you. Let us know your thoughts on Twitter with #ontheline, or send us a video message on Skype. http://bit.ly/1KLAjOD",
    "from": {
        "name": "VICE News",
        "id": "235852889908002"
    },
    "id": "557585337734754",
    "length": 32.064,
    "permalink_url": "/vicenews/videos/557585337734754/",
    "picture": "https://scontent.xx.fbcdn.net/hvthumb-xpt1/v/t15.0-10/p128x128/12323142_557586267734661_590161308_n.jpg?oh=4ccb2de17f95ed1be7d4e0ac64975ceb&oe=57795653",
    "source": "https://video.xx.fbcdn.net/hvideo-xpt1/v/t43.1792-2/12741453_433798730149138_852895459_n.mp4?efg=eyJybHIiOjE1MDAsInJsYSI6MTAyNCwidmVuY29kZV90YWciOiJzdmVfaGQifQ%3D&rl=1500&vabr=505&oh=bf736e83d68e1c9f7d7fe342e004da47&oe=56FC2AA0",
    "updated_time": {
        "date": "2016-02-25 12:00:03.000000",

```

```

        "timezone_type": 1,
        "timezone": "+00:00"
    },
    "thumbnails": [
        {
            "id": "557586204401334",
            "height": 720,
            "scale": 1,
            "uri": "https://scontent.xx.fbcdn.net/hvthumb-xft1/v/t15.0-10/12672212_557586237734664_1816489778_n.jpg?oh=c5e8ec4a17cce1f081fc90c8dcfde335&oe=577E8458",
            "width": 1280,
            "is_preferred": false
        },
        {
            "id": "557586264401328",
            "height": 720,
            "scale": 1,
            "uri": "https://scontent.xx.fbcdn.net/hvthumb-xpt1/v/t15.0-10/12323142_557586267734661_590161308_n.jpg?oh=2ee8e40bccbc066c76376a69fe8a52d3&oe=5789F700",
            "width": 1280,
            "is_preferred": true
        }
    ],
    "likesCount": 21,
    "commentsCount": 8,
    "sharedpostsCount": null,
    "viewCount": 2470,
    "time_date": "28-03-16 21:35:23",
    "page_name_id": "vicenews"
}

```

- Dailymotion:

```

{
    "allow_comments": true,
    "aspect_ratio": 1.7777777910233,
    "available_formats": [
        "l1",
        "l2",
        "ld",
        "sd",
        "hq",
        "hd720",
        "hd1080"
    ],
    "bookmarks_total": 0,
    "comments_total": 0,
    "country": "CN",

```

```

"created_time": "2016-03-24 15:21:33",
"date_time": "2016-03-24 22:06:18",
"description": "Jakis opis",
"duration": 892,
"embed_url": "http://www.dailymotion.com/embed/video/x3zv9ds",
"filmstrip_60_url": "http://static2.dmcdn.net/static/video/485/346/241643584.jpeg_preview_contact.jpg?20160324230220",
"id": "x3zv9ds",
"language": "zh",
"name_id": "zjtv",
"owner.id": "x1jfq5",
"sprite_320x_url": "http://s2.dmcdn.net/U20VK/320x-rAB.jpg",
"tags": [
    "\u4e2d\u56fd\u68a6\u60f3\u79c0",
    "\u5468\u7acb\u6ce2",
    "\u6d59\u6c5f\u536b\u89c6",
    "\u4e2d\u56fd\u68a6\u60f3\u79c0 0324",
    "\u4e2d\u56fd\u68a6\u60f3\u79c02016",
    "zhoulibo"
],
"thumbnail_url": "http://s2.dmcdn.net/U2zrm.jpg",
"title": "\u4e2d\u56fd\u68a6\u60f3\u79c0 \u7b2c9\u5b63 20160324\u671f:\u6b66\u672f\u8857\u821e\u521b\u610f\u878d\u5408\u5f70\u663e\u522b\u6837\u4e2d\u56fd\u98ce",
"url": "http://www.dailymotion.com/video/x3zv9ds_%E4%B8%AD%E5%9B%BD%E6%A2%A6%E6%83%B3%E7%A7%80-%E7%AC%AC9%E5%AD%A3-20160324%E6%9C%9F-%E6%AD%A6%E6%9C%AF%E8%A1%97%E8%88%9E%E5%88%9B%E6%84%8F%E8%9E%8D%E5%90%88%E5%BD%B0%E6%98%BE%E5%88%AB%E6%A0%B7%E4%B8%AD%E5%9B%BD%E9%A3%8E_tv",
"views_last_day": 8,
"views_last_hour": 0,
"views_last_month": 8,
"views_last_week": 8,
"views_total": 8
}

```

- Vimeo:

```

{
  "created_time": "2009-11-12T01:28:03+00:00",
  "date_time": "2016-03-25 19:58:14",
  "description": "cast ELIZA TAYLOR and TIM ROSS\nwriter director TIMOTHY MELVILLE\nproducer DOMINIC ALLEN\ncinematographer JOEL BETTS\nproduction company SCARAB STUDIO FILMS. 2009\n\nDownload the script here, http://tinyurl.com/kezzws4\nView the Spanish dub here, http://youtu.be/eYTJdv0JMhw\n\nOfficial Selection Flickerfest 2010\nOfficial Selection St Kilda Film Festival 2010\nOfficial Selection Dungog Film Festival 2010\nWinner Best Film Hillside Film",
  "duration": 397,
  "height": 640,

```

```

"language": null,
"link": "https://vimeo.com/timothymelville/thelaundromat",
"metadata": {
  "connections": {
    "comments": {
      "options": [
        "GET",
        "POST"
      ],
      "total": 122,
      "uri": "/videos/7563705/comments"
    },
    "credits": {
      "options": [
        "GET",
        "POST"
      ],
      "total": 3,
      "uri": "/videos/7563705/credits"
    },
    "likes": {
      "options": [
        "GET"
      ],
      "total": 2311,
      "uri": "/videos/7563705/likes"
    },
    "pictures": {
      "options": [
        "GET",
        "POST"
      ],
      "total": 1,
      "uri": "/videos/7563705/pictures"
    },
    "related": {
      "options": [
        "GET"
      ],
      "uri": "/channels/iphones/videos?fields=stats,description,language,privacy,pictures,duration,tags,uri,modified_time,height,width,link,created_time,name,user.uri,metadata&per_page=50&page=1&sort=date&direction=asc&offset=1"
    },
    "texttracks": {
      "options": [
        "GET",
        "POST"
      ],
    },
  }
}

```

```

        "total": 2,
        "uri": "/videos/7563705/texttracks"
    },
    "interactions": {
        "like": {
            "added": false,
            "added_time": null,
            "uri": "/users/49719331/likes/7563705"
        },
        "watchlater": {
            "added": false,
            "added_time": null,
            "uri": "/users/49719331/watchlater/7563705"
        }
    },
    "modified_time": "2016-03-25T19:11:25+00:00",
    "name": "The Laundromat | Short Film",
    "name_id": "iphones",
    "pictures": {
        "active": true,
        "sizes": [
            {
                "height": 480,
                "link": "https://i.vimeocdn.com/video/133977185_960x480.jpg?r=pad",
                "width": 960
            },
            {
                "height": 640,
                "link": "https://i.vimeocdn.com/video/133977185_1280x640.jpg?r=pad",
                "width": 1280
            }
        ],
        "type": "custom",
        "uri": "/videos/7563705/pictures/133977185"
    },
    "privacy": {
        "add": true,
        "comments": "anybody",
        "download": false,
        "embed": "public",
        "view": "anybody"
    },
    "stats": {
        "plays": 167662
    },
    "tags": [
        {

```

```

        "canonical": "shortfilm",
        "metadata": {
            "connections": {
                "videos": {
                    "options": [
                        "GET"
                    ],
                    "total": 188589,
                    "uri": "/tags/shortfilm/videos"
                }
            }
        },
        "name": "Short Film",
        "tag": "Short Film",
        "uri": "/tags/shortfilm"
    }
],
"uri": "/videos/7563705",
"user": {
    "uri": "/users/2621541"
},
"width": 1280
}

```

Roboty internetowe (wraz ich opisem) można znaleźć tutaj: <https://github.com/tom3097/VideoPopularityPrediction/tree/master/VideoCrawlers/src>. Dużym problemem było znalezienie bezprecedensowych url'i do filmików dla Youtube, Dailymotion oraz Vimeo. Ostatecznie udało mi się to osiągnąć za pomocą narzędzie youtube-dl, które można znaleźć tutaj: <https://github.com/rg3/youtube-dl>. Jednak wykorzystanie tego narzędzia drastycznie zwiększa czas działania crawlerów, ponadto linki są aktywne tylko przez pewien czas. Z tego powodu zdecydowałem się nie korzystać z niego do czasu, gdy url'e te będą mi rzeczywiście potrzebne.

### 1.3 Zapoznanie się z architekturą sztucznych sieci neuronowych

Ponieważ dotychczas nie miałem nic wspólnego z sieciami neuronowymi, musiałem poświęcić trochę czasu aby zapoznać się z ich podstawowymi zagadnieniami oraz ich architekturą. W pierwszym kroku zapoznałem się z podstawami "regularnych" sieci neuronowych. Następnie poznałem architekturę ConvNet. Wiedzę zdobywałem z tutoriala który można znaleźć tutaj: <http://cs231n.github.io/>. Ponadto zacząłem internetowe kursy <https://www.udacity.com/course/deep-learning--ud730> oraz <https://www.coursera.org/learn/machine-learning> (których jeszcze nie skończyłem, jednak pomogły mi zrozumieć podstawy).

### 1.4 Zapoznanie się z frameworkiem Caffe

Aby zapoznać się z Caffe przeczytałem oficjalną dokumentację, którą można znaleźć na ich stronie, bazując głównie na <http://caffe.berkeleyvision.org/tutorial/> oraz w mniejszym stopniu również na innych dokumentach.



## 1.5 Zapoznanie się z niezbędnymi API w Pythonie (Caffe, LMDB, numpy)

W tym celu przeanalizowałem niektóre z plików typu IPython Notebook które można znaleźć tutaj: <https://github.com/BVLC/caffe/tree/master/examples>. Wynikiem tych analiz były pewne skrypty implementujące sieci neuronowe, skrypty to ich testowania, używania itp. Nie stanowiły one jednak wartości "materialnej", służyły tylko mojemu zapoznaniu się, dlatego nie udostępniłem ich na repozytorium.

## 1.6 Normalizacja popularności filmików

Biorąc pod uwagę metadane, które dostępne są na każdym z czterech serwisów internetowych, czyli:


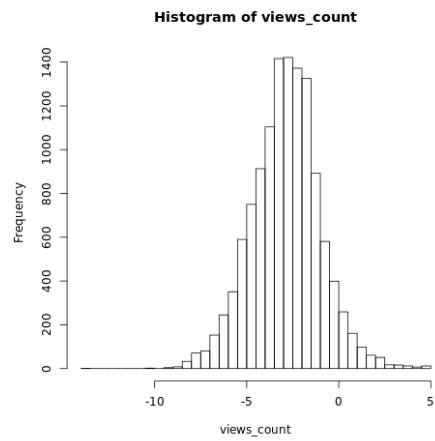


- liczba wyświetleń
- liczba followersów/subskrypcji dla kanału/użytkownika
- data publikacji

Wyznaczyłem wzór do normalizacji popularności filmików. Wygląda on w następujący sposób





```
normalizedPopularity = log_2( (viewsCount + 1)/followersCount )
```

Poniżej przedstawione zostały przykładowe wykresy popularności dla różnych serwisów: Youtube, Facebook, Dailymotion, Vimeo w miesiącach kolejno: 10.2015, 11.2015, 12.2015, 01.2016.





Rysunek 1: Youtube: 10.2015, 11.2015, 12.2015, 01.2016







Rysunek 2: Facebook: 10.2015, 11.2015, 12.2015, 01.2016



Rysunek 3: Dailymotion: 10.2015, 11.2015, 12.2015, 01.2016



Rysunek 4: Vimeo: 10.2015, 11.2015, 12.2015, 01.2016



Jak widać w przypadku filmików z Youtube czy też Facebooka otrzymujemy wykresy gaussowskie, dla filmików z Dailymotion otrzymujemy lekko przesunięte wykresy gaussowskie. Jedynie w przypadku filmików z Vimeo widać większe odstępstwa, jednak są one do zaakceptowania. Skrypty do tworzenia wykresów, wraz z opisem ich uruchamiania znajdują się tutaj: <https://github.com/tom3097/VideoPopularityPrediction/tree/master/GaussTest/src>.

## 1.7 Podział filmików na klasy popularności

Korzystając ze znormalizowanych popularności filmików dokonałem ich podziału na:

- dwie klasy popularności (binarnego)
- osiem klas popularności

Stworzone zostały skrypty do podziału filmików z Youtube oraz Facebooka, jednak podział filmików z Dailymotion oraz Vimeo odbywa się w analogiczny sposób. Skrypty te, wraz z wynikami ich uruchomień, można znaleźć tutaj: <https://github.com/tom3097/VideoPopularityPrediction/tree/master/Batches>.

## 1.8 Fine-tuning sieci neuronowej

Aby przeprowadzić fine-tuning, w pierwszej kolejności pobrałem miniaturki filmów z Facebooka (preferred) oraz Youtube. Skrypty do tego służące znajdują się tutaj: <https://github.com/tom3097/VideoPopularityPrediction/tree/master/ThumbDownloaders>. Następnie, korzystając z wytrenowanej wcześniej sieci Berkeley-trained models ([https://github.com/BVLC/caffe/tree/master/models/bvlc\\_reference\\_caffenet](https://github.com/BVLC/caffe/tree/master/models/bvlc_reference_caffenet)) przeprowadziłem fine-tuning zarówno dla binarnej klasyfikacji filmików jak i dla podziału na 8 kategorii. W przypadku Facebooka dla klasyfikacji binarnej otrzymałem:

- accuracy = 0.60312
- loss = 0.651064

Natomiast w przypadku podziału na 8 kategorii rezultaty prezentują się następująco:


- accuracy = 0.2064
- loss = 1.97498

Użyte pliki takie jak solvery, definicje sieci można znaleźć tutaj: <https://github.com/tom3097/VideoPopularityPrediction/tree/master/Nets>.


## 1.9 Wybór najlepszych i najgorszych miniaturek

W celu wybrania najlepszych i najgorszych miniaturek podłączyłem ostatnią warstwę typu FC na output. Korzystałem z wytrenowanej w poprzednim punkcie sieci za pomocą fine-tuningu dla podziału na 8 kategorii. Ponieważ kategoria 7 grupuje filmiki najbardziej popularne, posortowałem wyniki malejąco według punktów przyznanych tej kategorii. W ten sposób otrzymałem najlepsze miniaturki filmików. Analogicznie postąpiłem w przypadku wyznaczenia najgorszych miniaturek. Ponieważ kategoria 0 grupuje filmiki najmniej popularne, również posortowałem wyniki malejąco według tej kategorii, w tym przypadku otrzymując jednak najgorsze miniaturki filmików. Poniżej przedstawiam przykładowe 4 najlepsze i 4 najgorsze miniaturki wyznaczonych ze zbioru danych do testowania.

Rysunek 5: Przykładowe 4 najlepsze miniaturki



Rysunek 6: Przykładowe 4 najgorsze miniaturki



Skrypt użyty do wyznaczenia tych miniaturek można znaleźć tutaj: <https://github.com/tom3097/VideoPopularityPrediction/tree/master/BestWorstThumb>. Jak widać, chociaż miniaturka jest ważnym czynnikiem decydującym o popularności pliku video, nie jest ona czynnikiem decydującym.

### 1.10 Inne

Dodatkowo, specjalnie na potrzeby pracy inżynierskiej, nauczyłem się języka R (z którego potem korzystałem na równi z Pythonem). Zapoznałem się również z artykułami które otrzymałem, można je znaleźć tutaj: [https://github.com/tom3097/VideoPopularityPrediction/tree/master/Materials/research\\_papers](https://github.com/tom3097/VideoPopularityPrediction/tree/master/Materials/research_papers).

## 2 Plany na następny semestr

W następnym semestrze planuję zająć się między innymi implementacją i testowaniem CNN w przypadku filmików (już nie miniaturek). Dodatkowo planuję przeanalizować filmiki z dwóch pozostałych źródeł (w tej chwili kładłem nacisk na filmiki z youtube oraz facebooka, do zbadania zostały jeszcze filmiki z dailymotion oraz vimeo). Następnie planuję uwzględnić w predykcji również inne metadane jak komentarze, lajki itp. Ostatecznie mam również w planach formalne napisanie pracy.